



PROGETTO 3 • DATA & BI

BI Pipeline

Dalla riga grezza al cruscotto

Un milione di righe di vendite attraversano quattro strati indipendenti e idempotenti, si depositano in uno schema a stella testato, ed escono come cinque indicatori.

Python

ingestione

PostgreSQL

magazzino

dbt

trasformazioni

Prefect

orchestrazione

Docker

ambiente

Metabase

cruscotti

Sorgente Online Retail II • UCI Machine Learning Repository

1.067.371 righe • dicembre 2009 – dicembre 2011 • grossista britannico di articoli da regalo





Licenza CC BY 4.0 • Chen, D. (2012) • DOI 10.24432/C5CG6D

Imad El Mir • mockup di progetto

Sistema di design e strumenti

I colori che imposterò in Metabase, e la regola di cosa fa ciascun pezzo

TAVOLOZZA

					
Blu marchio #509EE3 serie principale, elementi attivi	Verde #88BF4D variazioni positive, test superati	Viola #A989C5 seconda serie, anno precedente	Giallo #F9CF48 avvisi, soglie	Salmone #EF8C8C resi, variazioni negative	Grafite #2E353B barra laterale

Tema chiaro, quello predefinito di Metabase. Il fondo delle schede resta bianco e il testo grigio-blu: su un cruscotto che si guarda per otto ore, il contrasto pieno stanca. **Una sola serie e' blu.** Se due serie sono entrambe blu, il grafico non si legge.

OGNI STRUMENTO FA UNA COSA SOLA

STRUMENTO	FA	NON FA
● Python	Scarica il file, ne verifica il checksum, lo carica in raw con COPY.	Non trasforma niente. Se il dato e' sporco entra sporco.
● PostgreSQL	Tiene i tre schemi raw, staging, marts e gli indici.	Non contiene logica: nessuna vista scritta a mano fuori da dbt.
● dbt	Pulizia, tipi, schema a stella, test, documentazione e lineage.	Non scarica dati e non parla con l'esterno.
● Prefect	Mette in fila i passi, ritenta la rete, registra tempi ed esiti.	Non contiene trasformazioni: quelle stanno in dbt.
● Docker	Alza PostgreSQL e Metabase con un comando, ovunque.	Non e' l'ambiente di sviluppo Python.
● Metabase	Disegna i cinque indicatori e i tre cruscotti su marts.	Non calcola niente: nessuna formula dentro un grafico.

TIPI DI GRAFICO E QUANDO

Numero singolo — i cinque indicatori. Con la variazione sotto, mai da solo: un numero senza confronto non dice se e' buono.

Linea — solo per il tempo. Due serie al massimo.

Barre orizzontali — classifiche. Le etichette lunghe si leggono, quelle verticali no.

Istogramma — distribuzione dello scontrino. La media da sola nasconde la forma.

Tabella — quando i valori vanno letti, non confrontati.

Niente torte, niente mappe di calore. La torta rende impossibile confrontare fette simili; la mappa di calore su quaranta paesi diventa decorazione.

Architettura, quattro strati

Ogni strato legge solo quello sotto, e si può rilanciare da solo

1

raw

Python + COPY

Le colonne entrano tutte come testo, con l'aggiunta della data di carico e del file d'origine. Nessuna conversione, nessun filtro.

Rilanciabile Cancella e ricarica per file, dentro una transazione. Tre esecuzioni lasciano sempre 1.067.371 righe.

2

staging

dbt • viste

Tipi, nomi in italiano, deduplica, esclusione dei codici di servizio e dei prezzi non positivi. Un modello per sorgente, nessun join.

Rilanciabile Sono viste: si ricalcolano a ogni interrogazione, quindi non hanno stato da sporcare.

3

marts

dbt • tabelle

Schema a stella: un fatto e quattro dimensioni, con chiavi surrogate. E' l'unico strato dove le cose si uniscono.

Rilanciabile Le dimensioni si ricostruiscono da zero. Il fatto e' incrementale sulla data, e una ricostruzione completa da' lo stesso totale.

4

presentazione

Metabase

Cinque indicatori, tre cruscotti. Legge soltanto da marts: non conosce l'esistenza di raw e staging.

Rilanciabile Non tiene dati propri: e' una finestra, non un contenitore.

PERCHÉ ELT E NON ETL

Le trasformazioni restano scritte in SQL **dentro il repository**: si leggono in una pull request, si testano con un comando, si annullano con un *revert*. In un ETL classico la logica vive dentro uno strumento, e per rivederla bisogna aprire quello strumento.

PERCHÉ L'IDEMPOTENZA CONTA

Se la pipeline muore a metà, la si rilancia e basta. Senza, un fallimento lascia dati a metà e l'unica via d'uscita è capire a mano cos'era entrato e cosa no — di notte, con il cruscotto già sbagliato davanti a qualcuno.


IL NUMERO DA MISURARE

COPY contro **pandas.to_sql** su centomila righe.

Il primo scrive a blocchi, il secondo emette un INSERT per riga. La differenza si misura in M2-T6 e finisce nel case study: è il genere di numero che rende credibile tutto il resto.

Il modello dimensionale

Un fatto, quattro dimensioni, e tre decisioni da spiegare a voce



La fattura non ha una tabella

Una `dim_fattura` conterrebbe solo la chiave e nient'altro: un join in più per zero informazione. Sta dentro il fatto come dimensione degenere. E' un caso da manuale, e vale la pena saperlo raccontare.

Il cliente Sconosciuto

Circa un quarto delle righe non ha il codice cliente. Sono vendite vere: buttarle falserebbe il fatturato. Puntano a una riga con chiave -1, e i clienti attivi la escludono.

Il calendario si genera

I giorni di chiusura non compaiono nelle vendite. Se la dimensione nascesse dai dati, un grafico giornaliero salterebbe le domeniche senza dirlo. Si genera l'intero periodo e i giorni vuoti restano visibili come zeri.

Cruscotto 1 • Andamento

La pagina che si apre per prima: come sta andando, rispetto a quando

- Metabase
- CRUSCOTTI
- Home
- Andamento
- Prodotti e clienti
- Geografia
- Qualità dei dati
- DATI
- marts
- Domande salvate

Andamento

aggiornato 4 minuti fa

Periodo: 2011

Paese: tutti

Resi: inclusi

FATTURATO NETTO

£ 8,91 M

▲ 6,4% sul 2010

ORDINI

36.412

▲ 3,1% sul 2010

SCONTRINO MEDIO

£ 244,7

▲ 3,2% sul 2010

TASSO DI RESO

2,1%

▼ 0,4 punti
sul valore, non sui pezzi

CLIENTI ATTIVI

5.878


▲ 8,0% sul 2010
Sconosciuto escluso

FATTURATO NETTO PER MESE



Il picco di novembre non è un errore: è un grossista di articoli da regalo, e i rivenditori si riforniscono **prima** del Natale. Dicembre cala perché i dati si fermano al giorno 9.

ORDINI PER MESE



LORDO, RESI, NETTO

Fatturato lordo £ 9,10 M

Resi - £ 0,19 M

Fatturato netto £ 8,91 M

Le tre righe stanno insieme di proposito: il netto da solo nasconde quanto rientra, e il tasso di reso è uno dei cinque indicatori.

DA SAPERE LEGGENDO QUESTA PAGINA

Gli ordini contano le fatture, non le righe: una fattura con dodici prodotti resta un ordine solo.

I resi sono dentro il netto come valori negativi, e fuori dal conteggio degli ordini.

Il confronto è con lo stesso mese dell'anno prima, non con il mese precedente: la stagionalità qui è fortissima.

I valori nelle schede sono segnaposto di impaginazione: i numeri veri arriveranno dai dati, alla milestone M7.

Metabase

CRUSCOTTI

Home

Andamento

Prodotti e clienti

Geografia

Qualità dei dati

DATI


marts

Domande salvate

Prodotti e clienti

aggiornato 4 minuti fa


Periodo: 2011 Paese: tutti Resi: inclusi



CLIENTI PER FATTURATO

CLIENTE	VALORE	ORDINI
14646 • Paesi Bassi	£ 280.206	77
18102 • Regno Unito	£ 259.657	62
17450 • Regno Unito	£ 194.551	55
14911 • Irlanda	£ 143.825	248
12415 • Australia	£ 124.914	26

Sono rivenditori, non consumatori: uno di questi fa da solo il fatturato di centinaia di clienti piccoli.



PRODOTTI CON PIÙ RESI

REGENCY TEA PLATE PINK	8,9%
SET OF 3 CAKE TINS	6,2%
GLASS STAR FROSTED	5,4%
HOME BUILDING BLOCK WORD	4,8%

Il tasso è sul valore, non sul numero di pezzi. Un reso da mille sterline non pesa quanto uno da due, e contarli uguali nasconde il problema vero.

I valori nelle schede sono segnaposto di impaginazione: i numeri veri arriveranno dai dati, alla milestone M7.

Metabase

CRUSCOTTI

Home

Andamento

Prodotti e clienti

Geografia

Qualità dei dati

DATI

marts

Domande salvate

Geografia

aggiornato 4 minuti fa

Periodo: 2011

Regno Unito: escluso

Resi: inclusi

FATTURATO PER PAESE

sterline

Paesi Bassi	285.446
Irlanda	263.277
Germania	221.698
Francia	197.404
Australia	137.077
Svizzera	56.385
Spagna	54.775
Belgio	40.911
Svezia	36.596
Norvegia	35.164

Il Regno Unito non c'è, ed è una scelta.

Vale l'82% del fatturato: con lui dentro, la sua barra arriva a fondo pagina e tutte le altre diventano trattini indistinguibili. Il suo peso si legge nella barra impilata qui a destra, che è il posto giusto per una proporzione.

MERCATO INTERNO CONTRO ESTERO

Regno Unito 82%

Eestero 18%

Una barra impilata e non una torta: due fette così diverse in un cerchio si leggono peggio, e la torta non permette di confrontare due periodi affiancati.

SCHEMA ITALIA

£ 16.891

42

15

fatturato netto

ordini

clienti

Da verificare prima di pubblicarla.

Se l'Italia risulta avere poche decine di ordini, la scheda lo dichiara invece di far sembrare significativo un campione minuscolo. Un numero su quindici clienti non è una tendenza.

VALORI DA NORMALIZZARE

La colonna del paese è testo libero, e contiene voci che non sono paesi: Unspecified, European Community, Channel Islands, EIRE per l'Irlanda. La normalizzazione avviene in dim_paese, con una tabella di raccordo versionata — non con una serie di CASE WHEN nascosti dentro un grafico.

I valori nelle schede sono segnaposto di impaginazione: i numeri veri arriveranno dai dati, alla milestone M7.

BI Pipeline • mockup • Imad El Mir

Cruscotto 3

7

Metabase

CRUSCOTTI

Home

Andamento

Prodotti e clienti

Geografia

Qualità dei dati

DATI

marts

Domande salvate

Qualità dei dati

aggiornato 4 minuti fa

Ultima esecuzione: oggi


Target: prod

ESITO DI dbt build

16 su 16 superati - 24 s

TEST	DOVE	N.	COSA IMPEDISCE
✓ unique	chiavi delle dimensioni	4	Chiavi doppie moltiplicano il fatturato nei join
✓ not_null	chiavi del fatto	4	Una chiave nulla fa sparire righe da ogni join interno
✓ relationships	fatto → dimensioni	4	Vendite di prodotti che non esistono in anagrafica
✓ accepted_values	is_reso	1	Che diventi un terzo stato per errore di tipo
✓ prezzo_positivo	staging	1	Che le rettifiche a prezzo zero rientrino di nascosto
✓ coerenza_resi	marts	1	Righe marcate reso con quantità positiva
✓ quadratura_totali	raw → marts	1	Che spariscano righe senza che nessuno lo sappia

LINEAGE GENERATO DA dbt docs



Il grafo non si disegna a mano: nasce dai riferimenti ref () dentro i modelli. Se qualcuno aggiunge una dipendenza, compare qui da sola.

LA QUADRATURA

Righe caricate in raw	1.067.371
- codici di servizio	- 9.847
- prezzo non positivo	- 6.202
- duplicati esatti	- 5.268
- descrizione mancante	- 4.382

Righe in fct_vendite1.041.672

È il test che quasi nessuno scrive. La somma delle righe escluse deve tornare al pezzo. Se in raw ce ne sono 1.067.371 e nel fatto ne arrivano meno del previsto, la differenza deve corrispondere esattamente alle esclusioni dichiarate. Altrimenti qualcosa sparisce lungo la strada, e il cruscotto mente senza che nessuno se ne accorga.

FRESCHEZZA DELLA SORGENTE

Ultimo caricamento 4 minuti fa

Soglia di avviso a 24 ore, di errore a 48. Su dati storici la freschezza non cambia mai — ma il controllo resta acceso perché il giorno che la sorgente diventa periodica, il meccanismo è già al suo posto.

Comandi e ordine di lavoro

Cosa si digita, in che ordine, e quando una milestone si può dire chiusa

IL Makefile

<code>make up</code>	Alza PostgreSQL e Metabase con Docker	~40 s la prima volta
<code>make ingest</code>	Scarica, verifica il checksum e carica in raw con COPY	da misurare, M2-T6
<code>make build</code>	Esegue dbt build: modelli e test insieme	~25 s su target dev
<code>make test</code>	Solo i test, senza ricostruire i modelli	~10 s
<code>make docs</code>	Genera e apre la documentazione dbt con il lineage	~15 s
<code>make flow</code>	Il flusso Prefect completo, dall'inizio alla fine	tutto in fila

Sei comandi, nessuno da ricordare a memoria. Chi clona il repository legge il README e digita `make up`: se serve altro, il README è scritto male.

I TRE PASSI CHE NON SI SALTANO

M1-T1 Leggere la licenza **prima** di scrivere codice. Se non fosse quella che dice, il progetto non si pubblica.

M2-T8 Idempotenza del caricamento. Senza, ogni rilancio raddoppia i dati — e te ne accorgi dal cruscotto sbagliato.

M5-T7 Quadratura dei totali. È l'unico test che si accorge se le righe spariscono per strada.

LE OTTO MILESTONE

M1	Fondamenta	chiude quando docker compose up alza PostgreSQL, la CI e' verde
M2	Ingestione	chiude quando un milione di righe in raw, ricaricabili senza duplicare
M3	Staging	chiude quando stg_vendite pulito, con i conteggi delle esclusioni
M4	Schema a stella	chiude quando un fatto, quattro dimensioni, fatto incrementale
M5	Qualita'	chiude quando tutti i test passano, la quadratura torna
M6	Orchestrazione	chiude quando Prefect esegue tutto con un comando
M7	Cruscotti	chiude quando i cinque indicatori su tre pagine
M8	Pubblicazione	chiude quando README, diagramma, case study nel portfolio

Ogni milestone chiude con una relazione in docs/milestones/: cosa è stato costruito, quali decisioni, con quali numeri misurati. Da quei file nasce il case study — scriverli è già metà della pubblicazione.

DUE COSE CHE NON SI FANNO

Non inventare il costo per calcolare il margine. Nessun dataset pubblico lo contiene, ed è la scorciatoia più facile da smascherare in un colloquio.

Non mettere formule dentro Metabase. Un calcolo scritto in un grafico non è versionato, non è testato e non lo ritrova più nessuno. Se serve un numero nuovo, nasce in dbt.